

CS240: 算法设计与分析

分布式影响力最大化中的子模优化与贪心近似算法

带通信约束候选共享的课程规模复现

Yixin Chen Bichi Zhang Yaoqin Ye

2026 年春季学期

- **选题：**影响力最大化。
- **问题：**在网络中选择 k 个种子节点，使期望扩散范围最大。
- **算法视角：**单调子模最大化、贪心近似、CELF 懒惰求值。
- **拓展：**GreeDI 风格的局部候选共享，并显式考虑通信预算。

核心实验信息

质量、运行时间和通信量之间存在真实权衡。

最清楚的算法收益

CELF 在 large 设置下减少约 74% 的 spread evaluations。

为什么研究影响力最大化？

- 网络扩散出现在营销传播、公共信息推送和虚假信息控制等场景。
- 问题形式很直观，但精确求解通常代价很高。
- 它能自然连接现代网络数据应用与经典近似算法。

本次汇报怎么展开？

- 将 IC 影响范围形式化为子模优化目标。
- 比较 greedy、CELFF 和轻量结构性基线。
- 分析通信受限时，只共享局部候选会带来什么变化。

$$\max_{S \subseteq V, |S| \leq k} \sigma(S)$$

- $G = (V, E, p)$ 是带边激活概率 p_{uv} 的有向图。
- $\sigma(S)$ 表示从种子集合 S 出发后的期望激活节点数。
- 独立级联模型：
 - 新激活节点对每个未激活出邻居只有一次激活机会；
 - 每次激活尝试以概率 p_{uv} 独立成功。
- 实验采用 weighted-cascade 规则： $p_{uv} = 1/\text{indegree}(v)$ 。

为什么可以用贪心

- IC 模型下的期望影响范围是**单调**的：增加种子不会降低扩散范围。
- 它也是**子模**的：种子集合越大，新节点带来的边际收益越小。

$$\sigma(A \cup \{v\}) - \sigma(A) \geq \sigma(B \cup \{v\}) - \sigma(B)$$

$$A \subseteq B, \quad v \notin B$$

近似保证

精确目标下，greedy 有 $(1 - 1/e)$ 近似保证。

实际加速

CELf 将旧边际收益作为当前上界来减少重算。

基线方法

- 随机种子
- 加权出度
- PageRank

中心化方法

- Monte Carlo greedy
- CELF 懒惰贪心
- 对最终种子集合公平再评估

分布式方法

- $m \in \{2, 4, 8\}$ 个分区
- 本地预算 $q \in \{k, 2k, 5k\}$
- 协调器在合并候选池上运行 greedy


代码模块

- `simulation.py`: IC 扩散与 spread 估计
- `greedy.py`: greedy 与 CELF
- `distributed.py`: 局部候选共享
- `experiments.py`: benchmark sweep 与 CSV 输出

实验设置

- Small: ER/BA/WS 的 $n = 40, 70$, 加 Karate $n = 34$
- Large: ER/BA/WS 的 $n = 50, 100, 200$, 加 Karate
- 种子预算: small 为 $k = 5, 6$; large 合成图 为 $k = 10$
- 指标: spread、相对 greedy 质量、运行时间、估计次数、传输候选数

Benchmark 图结构



这些图族分别覆盖随机连接、hub 结构、小世界局部性，以及一个小型真实社交网络。


Large 设置下的核心结果

方法	Spread	Ratio	Time (s)	Eval.
Random	31.59	0.79	0.00	1.0
Weighted degree	43.71	1.07	0.01	1.0
PageRank	35.19	0.89	0.00	1.0
Greedy	40.43	1.00	4.67	1026.5
CELf	40.05	0.99	0.77	266.2


- CELf 基本保持 greedy 的平均质量，但显著减少 spread evaluations。
- 在 weighted-cascade 概率下，weighted degree 是很强的结构性基线，尤其适合 hub 明显的图。

不同图实例上的质量表现

Estimated IC spread



Quality ratio to greedy




每个最终种子集合都使用同一个 evaluation seed 重新估计 spread, 再计算相对 greedy 的质量比例。

分布式通信权衡


预算	Ratio	Time	Eval.	Cand.
small, $q = k$	0.97	0.23	364	25.0
small, $q = 2k$	0.96	0.42	557	38.8
small, $q = 5k$	0.94	0.63	727	50.6
large, $q = k$	0.98	1.58	1242	41.1
large, $q = 2k$	0.96	3.36	2037	66.9
large, $q = 5k$	0.96	6.48	3044	98.4

上表对 $m \in \{2, 4, 8\}$ 取平均。




运行时间与估计次数

Runtime (seconds)



Spread evaluations



分布式 greedy 会做额外的本地搜索；只有 worker 可以并行运行，或完整中心化搜索受数据归属/内存/通信限制时，这部分额外成本才更合理。

结果解释与局限

已经完成的部分

- 复现了子模 greedy 的核心机制。
- CELF 展示了清楚的实际加速效果。
- 分布式候选共享在很多设置下接近 greedy 质量。

需要诚实说明的部分

- 课程规模模拟次数下，Monte Carlo 选择存在噪声。
- 结构性基线在公平再评估后可能超过 greedy。
- 当前分布式运行是顺序模拟；真正加速需要并行 worker。

后续可做：更多随机种子、置信区间、更大真实网络、确定性划分，以及 RR-set 最大覆盖方法。

- 影响力最大化很好地展示了经典算法如何服务现代网络数据问题。
- IC 模型下的影响范围是单调子模函数，因此 greedy 近似提供了理论主线。
- CELF 说明子模性不只是证明工具，也能转化为实际加速。
- GreeDI-style 候选共享把问题推进到通信受限的分布式优化场景。
- 关键经验不是某个方法永远最好，而是图结构、估计精度和通信预算共同决定效果。