

实验报告

分布式影响力最大化中的子模优化与贪心近似算法

Yixin Chen

Bichi Zhang

Yaoqin Ye

CS240: 算法设计与分析, 2026 年春季学期

摘要

本项目研究影响力最大化问题：在网络中选择少量初始种子节点，使信息、行为或干预经过扩散后覆盖尽可能多的节点。按照课程项目要求，我们将现代网络数据应用与经典算法联系起来，重点讨论单调子模最大化、贪心近似、懒惰求值，以及带通信约束的分布式候选节点共享方法。项目实现了独立级联模型模拟、随机/度数/PageRank 基线、中心化 Monte Carlo 贪心、CELF 懒惰贪心，以及 GreeDI 风格的分布式局部候选合并算法。实验在合成图和小型真实图上进行。结果表明，在小图和低模拟次数设置下，结构性基线有时非常强；CELF 可以在保持相似目标质量的同时减少影响力估计次数；分布式候选共享则展示了质量、运行时间和通信预算之间的权衡。

1 背景与相关工作

影响力最大化是社交网络、病毒式营销、公共卫生干预和虚假信息分析中的经典问题。给定一个网络和有限预算，我们希望选择若干种子节点，使扩散过程最终激活的节点数量尽可能多。这个问题不是单纯的数据分析问题，而是带随机扩散过程的组合优化问题。

Kempe、Kleinberg 和 Tardos [1] 在独立级联模型 (Independent Cascade, IC) 和线性阈值模型 (Linear Threshold, LT) 下系统提出了影响力最大化问题，证明其为 NP-hard，并证明期望影响范围函数具有单调性和子模性。Nemhauser、Wolsey 和 Fisher 的经典结论 [2] 说明，在基数约束下最大化非负单调子模函数时，贪心算法具有 $(1 - 1/e)$ 近似保证。

实际困难在于，精确计算影响范围通常代价很高。朴素实现需要对大量候选种子集合做 Monte Carlo 扩散模拟。Leskovec 等人 [3] 提出的 CELF 方法利用子模函数边际收益递减性质，跳过大量不必要的重新估计。对于大规模或分布式场景，Mirzasoleiman 等人 [4] 提出的 GreeDI 方法将元素集合划分到多个机器上，先局部贪心，再合并局部代表元素。TIM/IMM 等方法 [5, 6] 使用反向影响采样进一步提升规模化能力；本项目将它们作为相关工作，而不作为完整复现目标。

2 问题形式化

设 $G = (V, E, p)$ 为有向图，每条边 (u, v) 具有传播概率 $p_{uv} \in [0, 1]$ 。给定种子预算 k ，影响力最大化问题为

$$\max_{S \subseteq V, |S| \leq k} \sigma(S),$$

其中 $\sigma(S)$ 表示以 S 为初始种子集合时，扩散结束后的期望激活节点数。

本项目主要使用独立级联模型。节点 u 第一次被激活后，对每个尚未激活的出邻居 v 有且仅有一次激活机会，成功概率为 p_{uv} 。所有边上的激活尝试相互独立，直到没有新的激活节点为止。

在 IC 模型下， σ 是单调子模函数：

$$\sigma(A \cup \{v\}) - \sigma(A) \geq \sigma(B \cup \{v\}) - \sigma(B), \quad A \subseteq B, v \notin B.$$

这种边际收益递减性质是贪心算法具有理论保证的原因，也是 CELF 能够把旧边际收益作为当前上界的原因。

3 代表性方法分析

3.1 中心化贪心

中心化贪心算法从 $S_0 = \emptyset$ 开始。在第 t 轮选择

$$v^* = \arg \max_{v \in V \setminus S_t} (\hat{\sigma}(S_t \cup \{v\}) - \hat{\sigma}(S_t)),$$

其中 $\hat{\sigma}$ 为 Monte Carlo 模拟得到的 IC 影响范围估计。随后令 $S_{t+1} = S_t \cup \{v^*\}$ ，直到 $|S| = k$ 。

若图有 n 个节点、 m 条边，一次 IC 模拟最坏情况下需要 $O(n + m)$ 时间。若每次影响力估计使用 R 次模拟，则朴素贪心的代价约为

$$O(knR(n + m)).$$

这在课程项目的小图上可以运行，但在大规模网络上很快变得昂贵。

3.2 CELF 懒惰贪心

CELF 用优先队列维护候选节点的缓存边际收益。由于子模性保证种子集合增大后某个节点的边际收益不会增加，旧边际收益可以作为当前边际收益的上界。当队首节点的边际收益已经是在当前种子集合大小下计算得到时，算法可以直接选择它；否则只重新计算这一个节点并放回队列。CELF 目标上仍然对应贪心选择，但通常显著减少影响力估计次数。

3.3 GreeDI 风格分布式贪心

分布式部分将节点集合划分为 m 个局部部分。第 i 个 worker 在本地候选节点上运行贪心，并返回最多 q 个候选节点。协调器形成候选池

$$C = \bigcup_{i=1}^m C_i,$$

再只在 C 上运行最终贪心选择。本项目测试 $m \in \{2, 4, 8\}$ 和 $q \in \{k, 2k, 5k\}$ 。通信代价用传输候选节点数量近似，即约为 mq ，但受每个分区大小上限限制。

4 复现与实现

代码结构如下：

- `src/simulation.py`: 独立级联模拟与 Monte Carlo 影响范围估计；
- `src/baselines.py`: 随机、加权出度和 PageRank 种子选择；
- `src/greedy.py`: 中心化贪心与 CELF 懒惰贪心；
- `src/distributed.py`: 随机节点划分与 GreeDI 风格候选共享；
- `src/graphs.py`: benchmark 图构造与 weighted-cascade 概率设置；
- `src/experiments.py`: 端到端实验运行与 CSV 结果输出。

由于完整复现大规模影响力最大化系统超出了课程项目范围，我们复现的是核心算法机制：IC 扩散估计、贪心子模选择、CELF 懒惰求值，以及分布式局部候选合并。实验共包含六个图实例：40/70 节点的 Erdos-Renyi 图、40/70 节点的 Barabasi-Albert 图、60 节点的 Watts-Strogatz 图，以及 34 节点的 Zachary Karate Club 图。种子预算根据图实例设置为 $k = 5$ 或 $k = 6$ 。

为了提高不同算法之间的可比性，每个算法得到最终种子集合后，都使用同一个评估随机种子重新估计影响范围。因此报告中的 `estimated_spread` 不是算法选择过程中内部使用的估计值，而是最终种子集合的公平再评估结果。

5 实验评估

5.1 整体算法比较

表 1 汇总了所有图实例上的平均结果。其中 `ratio` 表示相对于同一图实例中心化贪心结果的质量比例。

表 1: 所有 benchmark 实例上的平均性能。

算法	Spread	Ratio	Runtime (s)	Evaluations
Random	16.58	0.93	0.00	1.0
Degree	24.42	1.37	0.00	1.0
PageRank	22.92	1.27	0.00	1.0
Greedy	18.08	1.00	0.06	283.5
CELF	18.92	1.04	0.02	112.0
Best distributed average setting	24.00	1.34	0.32	359.5

一个需要诚实说明的现象是：当前小规模实验中，贪心并没有稳定超过结构性基线。Degree 和 PageRank 在这些图上表现很强，尤其 weighted-cascade 概率规则本身会让高度数或中心位置节点更有优势。这并不构成对贪心近似定理的反例：理论比较的是精确子模目标下的贪心解与最优解，而本项目实现中选择阶段使用的是带噪声的 Monte Carlo 估计，最终又用另一个随机种子进行公平再评估。

CELF 的表现符合预期：平均影响范围与贪心接近，但影响力估计次数从 283.5 降到 112.0，展示了懒惰求值的实际作用。




图 1: 不同图规模和算法下的 IC 影响范围估计。

5.2 分布式通信权衡

表 2 汇总了分布式变体。记号 $(m, q/k)$ 表示 m 个分区以及本地候选预算 $q = (q/k) \cdot k$ 。

表 2: 不同分区数和通信预算下的平均分布式性能。

Setting	Spread	Ratio	Runtime (s)	Evaluations	Candidates
(2, 1)	21.58	1.19	0.30	321.5	11.0
(2, 2)	21.00	1.16	0.64	591.5	22.0
(2, 5)	21.50	1.20	1.37	1021.5	49.0
(4, 1)	24.00	1.34	0.32	359.5	22.0
(4, 2)	21.50	1.18	0.61	599.8	43.0
(4, 5)	22.08	1.22	0.71	683.8	52.3
(8, 1)	22.00	1.21	0.42	430.5	43.0
(8, 2)	21.00	1.16	0.58	503.2	52.3
(8, 5)	21.92	1.22	0.51	503.2	52.3

分布式结果清楚展示了成本侧的权衡：更大的本地预算通常带来更多传输候选节点和更多 spread evaluations。质量侧更有噪声。在若干图实例中，分布式候选共享经过公平再评估后超过了中心化贪心。这可能是因为局部贪心增加了候选池多样性，也可能是中心化贪心在选择阶段受到 Monte Carlo 噪声影响。因此该现象应被解释为“小图上候选共享具有竞争力”，而不是理论上优于中心化贪心。




图 2: 相对于中心化贪心的质量比例。




图 3: 通信代价近似: 传输候选节点数量。

5.3 运行时间与估计次数

在当前小图上，中心化贪心的绝对运行时间并不高，但其估计次数会随 k 和候选节点数量增长。CELF 通过复用边际收益上界减少重新估计。分布式变体总估计次数更高，因为每个 worker 运行一轮本地贪心，协调器还要运行一轮最终贪心。只有当 worker 可以并行执行，或者完整图候选搜索因为内存、数据归属或隐私约束而不可行时，这种额外计算才是合理的。




图 4: 影响力估计次数。CELF 相比朴素贪心减少了估计次数。




图 5: 当前 benchmark 上的 wall-clock runtime。

6 偏差、局限与可选拓展

proposal 中提到更大的合成图和 Wiki-Vote、NetHEPT 等真实网络。当前复现使用较小图实例，是为了让完整实验能在课程项目环境中快速运行。这使实现更透明，但限制了可扩展性结论。

另一个限制是 Monte Carlo 噪声。为了控制运行时间，当前实验使用的模拟次数较少，分布式局部选择阶段使用的模拟次数还进一步降低。因此最终种子集合可能对随机性较敏感。这解释了为什么公平再评估有时会让 degree 或 distributed 变体高于中心化 greedy。更强的最终实验应增加模拟次数，在多个随机种子上重复实验，并报告置信区间。

本项目已经实现的可选拓展是 GreeDI 风格的通信受限变体。进一步可做的拓展包括确定性图划分策略、更大真实数据集、基于 RR-set 的最大覆盖方法，以及真正并行执行 worker 以测量分布式加速效果。

7 结论

本项目展示了如何用经典算法理解现代网络问题。IC 扩散模型下的影响力最大化具有单调子模目标；贪心选择提供近似保证；CELFG 将子模性转化为实际加速；GreeDI 风格候选共享则把问题连接到通信受限的分布式优化。虽然实验规模较小，但已经复现了核心算法机制，并揭示了一个重要实践问题：影响力最大化的效果不仅取决于近似算法本身，也取决于扩散估计精度、图结构和通信限制。

参考文献

- [1] D. Kempe, J. Kleinberg, and E. Tardos. Maximizing the spread of influence through a social network. *KDD*, 2003.
- [2] G. L. Nemhauser, L. A. Wolsey, and M. Fisher. An analysis of approximations for maximizing submodular set functions. *Mathematical Programming*, 1978.
- [3] J. Leskovec, A. Krause, C. Guestrin, C. Faloutsos, J. VanBriesen, and N. Glance. Cost-effective outbreak detection in networks. *KDD*, 2007.
- [4] B. Mirzasoleiman, A. Karbasi, R. Sarkar, and A. Krause. Distributed submodular maximization: Identifying representative elements in massive data. *NeurIPS*, 2013.
- [5] Y. Tang, X. Xiao, and Y. Shi. Influence maximization: Near-optimal time complexity meets practical efficiency. *SIGMOD*, 2014.
- [6] Y. Tang, Y. Shi, and X. Xiao. Influence maximization in near-linear time: A martingale approach. *SIGMOD*, 2015.